Modelo Analítico en Python para la Evaluación de Riesgos en la Cadena Global de Suministro: Un Enfoque Basado en ISO 31000

Urdaneta Ana

Resumen

La creciente complejidad de las cadenas globales La creciente complejidad de la cadena de suministro exige herramientas capaces de identificar y priorizar riesgos de forma objetiva. Este estudio desarrolló un modelo reproducible en Python para evaluar riesgos logísticos en operaciones marítimas internacionales, integrando variables operativas, climáticas, geopolíticas y de desempeño. La metodología incluyó limpieza de datos, normalización Min-Max, construcción de un índice de impacto y una matriz de riesgo alineada con ISO 31000. Los resultados permitieron detectar rutas críticas y factores predominantes de interrupción. Se concluye que la automatización analítica en Python mejora la toma de decisiones y favorece una gestión preventiva del riesgo logístico.

Palabras clave: Python, cadena de suministro, ISO 31000, análisis de datos, logística, gestión de riesgos.

Introducción

Las cadenas de suministro globales funcionan en entornos cambiantes donde el clima, los conflictos internacionales, los retrasos operativos o fallos de proveedores pueden generar pérdidas importantes. En sectores como energía, manufactura y comercio exterior, anticipar estos problemas es una ventaja competitiva.

La norma ISO 31000 ofrece una guía para identificar, analizar y gestionar riesgos de forma ordenada, ayudando a priorizar rutas, asignar recursos y preparar planes de contingencia.

Al mismo tiempo, el uso de datos y herramientas como Python permite analizar grandes volúmenes de información, detectar patrones y apoyar mejores decisiones.

Este trabajo presenta un modelo desarrollado en Python para evaluar riesgos en rutas logísticas internacionales, combinando gestión de riesgos y análisis de datos de forma práctica.

Metodología

1. Fuente de datos

Se utilizó el archivo **global_supply_chain_risk_2026.csv**, con registros de envíos internacionales y variables operativas, climáticas y geopolíticas, entre ellas: tiempo de entrega, distancia, peso, severidad climática, fiabilidad del carrier, riesgo geopolítico, puertos de origen y destino, y fecha.

El análisis se desarrolló en **Python (Jupyter Notebook)** utilizando **pandas**, **numpy**, **matplotlib**, **seaborn** y **plotly** para procesamiento, análisis y visualización de datos.

La preparación incluyó revisión de valores faltantes, detección de duplicados, corrección de tipos de datos y estandarización de variables categóricas.

Los valores extremos no fueron eliminados, al considerarse posibles eventos reales de disrupción. La severidad climática se codificó de forma ordinal (*Clear < Fog < Rain < Storm < Hurricane*).

Finalmente, se aplicó una normalización **Min-Max** para llevar las variables a una escala común entre 0 y 1:

Se aplicó escalamiento Min-Max:

$$x' = \frac{x - min(x)}{max(x) - min(x)}$$

Esto permitió comparar variables heterogéneas en una escala común [0,1].

4.4 Índice compuesto de impacto

Se integraron tres dimensiones: retraso logístico, distancia recorrida, peso transportado

El resultado fue una métrica única de impacto operacional, consistente con la metodología de indicadores compuestos de la OECD.

5. Matriz de riesgo ISO

Se combinó p**robabilidad** en base a la frecuencia relativa de disrupciones por ruta, e **impacto,** como índice compuesto normalizado

Con base en percentiles, las rutas fueron clasificadas como: critical, high, medium y low

---

Resultados

El análisis desarrollado en Python permitió identificar patrones relevantes de riesgo operacional en la red logística evaluada, integrando variables de desempeño, confiabilidad, entorno externo y comportamiento por ruta. Las salidas gráficas obtenidas facilitaron la interpretación ejecutiva de los hallazgos y la priorización de decisiones estratégicas.

1. Distribución de variables clave

La exploración inicial mostró una distribución heterogénea entre las variables analizadas, con alta dispersión y valores atípicos, especialmente en tiempo de entrega y riesgo geopolítico. Estos valores extremos se interpretaron como eventos reales de disrupción y no como errores de datos.

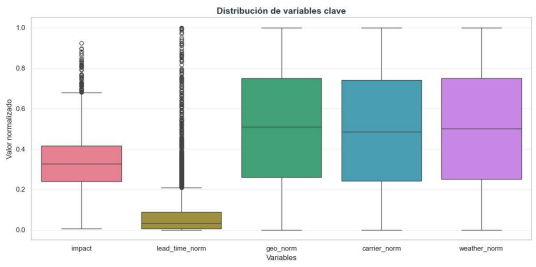

Figura 1. Distribución de variables clave mediante boxplots

2. Relaciones estructurales entre variables operativas

El análisis bivariado mostró que ninguna variable explica por sí sola las disrupciones. No obstante, la combinación de factores mejoró la identificación de rutas críticas, destacando la confiabilidad del transportista como la señal individual más relevante.

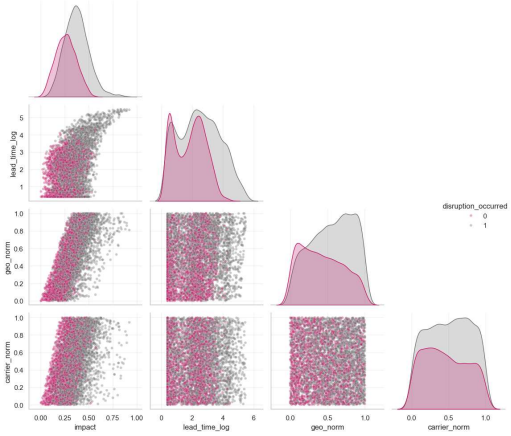

Figura 2. Matriz de relaciones entre variables operativas

Este resultado confirma que el riesgo logístico es un fenómeno multicausal, donde la convergencia de variables operativas y contextuales genera escenarios de mayor vulnerabilidad.

3. Impacto de la severidad climática

Se observó una relación creciente entre severidad climática e impacto operacional: en condiciones normales el efecto fue estable, pero ante eventos extremos se volvió más impredecible. Esto indica que el clima actúa como una variable de umbral y justifica su uso como señal de alerta dentro del modelo de riesgo.

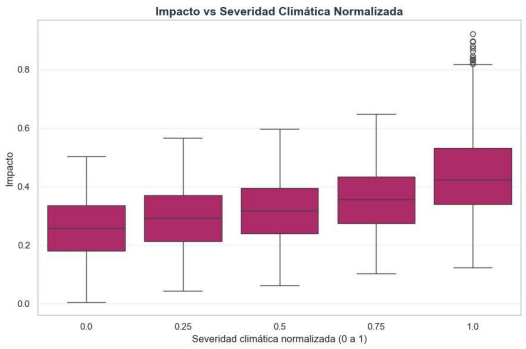

Figura 3. Impacto vs severidad climática normalizada

4. Factores que generan impacto

La matriz de correlación mostró que el impacto total se asocia principalmente con retrasos acumulados, riesgo geopolítico y desempeño del carrier. Esto indica que el riesgo depende tanto del contexto externo como de la calidad de ejecución logística.

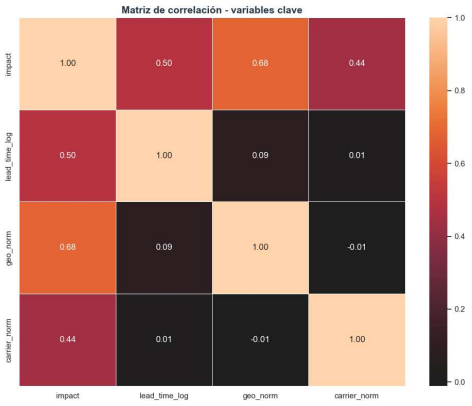

Figura 4. Matriz de correlación de variables clave

5. Ranking de rutas disruptivas y drivers asociados

El algoritmo en Python generó un ranking de rutas críticas, destacando Busan–Marseille, Shanghai–Marseille y Rotterdam–Marseille entre las más sensibles.

Figura 5. Proceso para identificar top 10 rutas disruptivas y drivers de riesgo

Los principales drivers de riesgo se agruparon en factores operativos, geopolíticos y relacionados con el carrier, permitiendo definir acciones específicas según cada ruta.

6. Disrupciones por ruta

El mapa de calor confirmó que el riesgo no se distribuye de forma uniforme entre rutas. Busan–Marseille presentó la mayor criticidad con predominio operacional, mientras Singapore–Antwerp destacó por mayor exposición geopolítica, lo que evidencia la necesidad de estrategias diferenciadas por corredor.

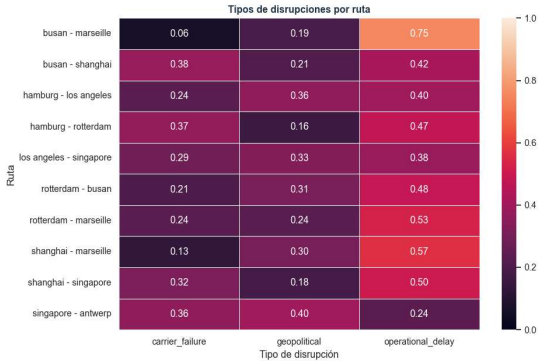

Figura 6. Heatmap de disrupciones por ruta

7. Matriz de riesgo y tabla de decisiones

Siguiendo el enfoque de ISO 31000, se construyó Se construyó una matriz de riesgo basada en probabilidad e impacto que clasificó las rutas en niveles Low, Medium, High y Critical.

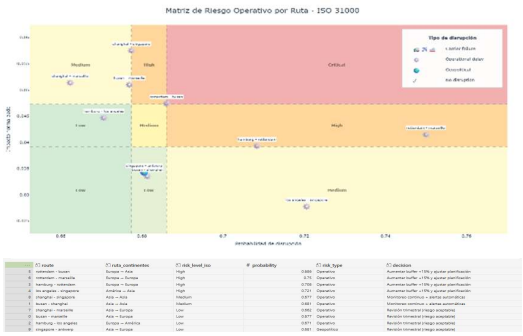

Figura 7. Matriz de riesgo operativo por ruta – ISO 31000

Las rutas críticas requieren acciones inmediatas, mientras las de riesgo medio necesitan seguimiento preventivo. Python permitió

automatizar la actualización del ranking y la clasificación con nuevos datos.

Discusión

Los resultados confirman que Python es una herramienta estratégica para transformar datos operacionales en decisiones empresariales objetivas y accionables. El modelo permitió responder preguntas clave sobre rutas críticas, drivers de riesgo y asignación de recursos, integrando variables internas y externas en un enfoque alineado con las fases centrales de ISO 31000.

Fase ISO 31000	Aplicación en Python
Identificación	Variables operativas, climáticas y geopolíticas
Análisis	Limpieza, normalización, scoring y correlaciones
Evaluación	Ranking de rutas y matriz probabilidad-impacto
Tratamiento	Priorización de acciones por nivel de criticidad
Monitoreo	Visualizaciones y actualización automatizada

La solución desarrollada es escalable, ya que permite incorporar nuevos datos sin rediseñar el proceso analítico. Para sectores intensivos en logística, esto supone una ventaja competitiva al facilitar la anticipación de interrupciones, reducir costes y mantener la continuidad operativa.

Conclusiones

El presente estudio demostró que Python es una plataforma robusta y flexible para desarrollar modelos de evaluación de riesgo logístico alineados con estándares internacionales. Mediante procesos de limpieza, transformación, normalización y visualización, fue posible convertir datos heterogéneos en información estratégica para la toma de decisiones.

Los principales hallazgos indican que:

- El riesgo presenta una distribución heterogénea entre rutas, variando en probabilidad e impacto.
- Marseille concentra corredores con mayor criticidad operacional.
- Singapore–Antwerp requiere seguimiento prioritario por exposición geopolítica.
- El riesgo operativo es predominante, aunque amplificado por factores externos.
- La combinación de variables explica mejor la disrupción que cualquier indicador aislado.

Desde una perspectiva aplicada, la analítica desarrollada facilita priorizar inversiones, diseñar estrategias de mitigación y fortalecer la resiliencia organizacional. La integración entre ciencia de datos e ISO 31000 ofrece un marco moderno para decisiones ágiles, transparentes y preventivas.

Como línea futura, el modelo puede evolucionar hacia sistemas predictivos en tiempo real, incorporando machine learning, simulación Monte Carlo y monitoreo automatizado de eventos globales.

Referencias

International Organization for Standardization. (2018). *ISO 31000:2018 Risk management—Guidelines*. ISO.

Organisation for Economic Co-operation and Development. (2008). *Handbook on constructing composite indicators: Methodology and user guide*. OECD Publishing.

Tukey, J. W. (1977). *Exploratory data analysis*. Addison-Wesley.

McKinney, W. (2022). *Python for data analysis* (3rd ed.). O'Reilly Media.

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95.